OceanBase

OceanBase
湖库一体的 AI 数据库

杨传辉 | OceanBase CTO

从 HTAP 到 LTAP：AI 数据库走向一体化融合

共同趋势：数据库全面补 AI 能力

向量索引、全文 + 向量混合搜索、Embedding、AI 算子
正在从专用能力变成数据库标配

Vector Index | Hybrid Search | RAG | AI Operators

湖仓补 OLTP 01

LTAP

湖仓从分析底座扩展到事务、应用状态与 Agent memory，把交易数据直接接入分析和 AI 应用

代表作品

Databricks LTAP / Lakebase

交易库补 OLAP 02

HTAP + 外表

交易数据库通过分布式架构、列存/分析引擎、外部表和湖仓连接，增强实时分析能力

代表作品

Oracle / OceanBase / MySQL HeatWave

专用库补通用能力 03

泛数据库化

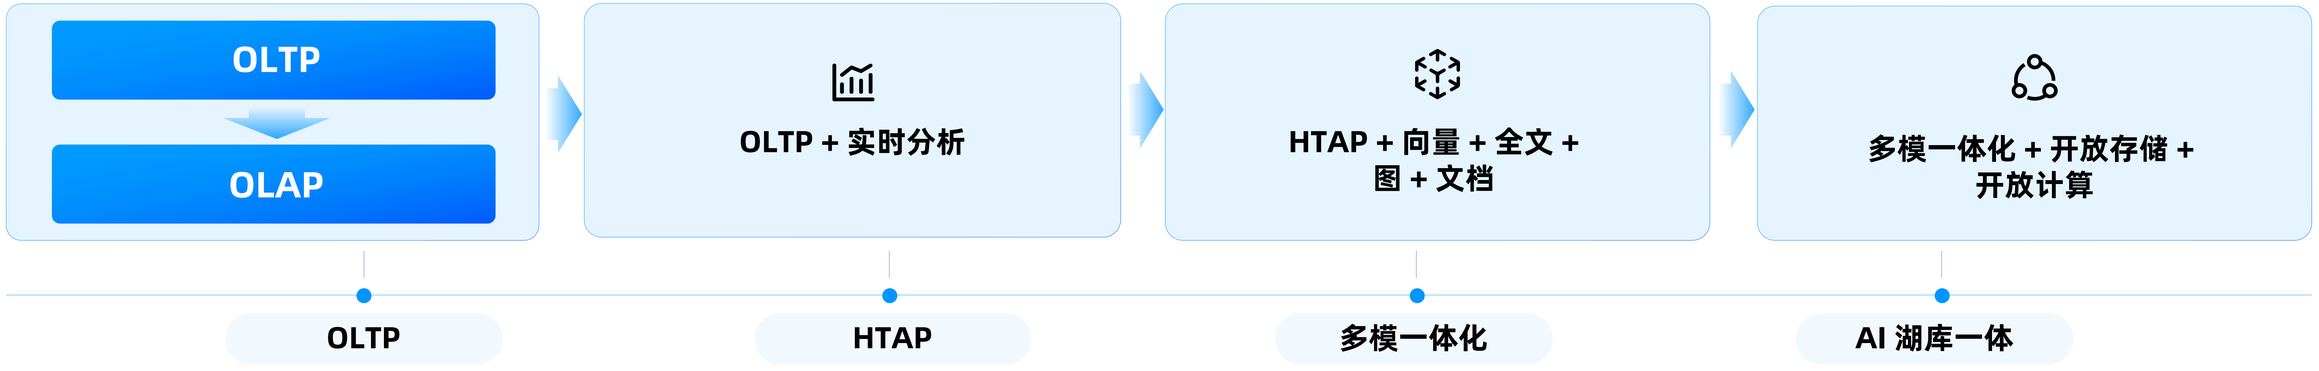
文档、向量、搜索库补齐事务、权限、治理、多租户、备份、过滤与结构化查询能力

代表作品

MongoDB / Milvus / Elastic / OpenSearch

AI 数据库的一体化，不是某一类数据库胜出，而是所有数据库都在向交易 + 分析 + 搜索 + 向量 + AI 的统一平台收敛

OceanBase：从分布式数据库到湖库一体的 AI 数据库



特性	OLTP 数据库	HTAP 数据库	一体化数据库	AI 湖库一体
数据类型	关系表	关系表	多模态（表/文本）	多模态（表/文本/视频/图像）
工作负载	交易型	交易 + 分析	交易 + 分析 + 搜索	交易 + 分析 + 搜索 + AI 计算（Spark/Ray）
架构类型	存算一体、行存	存算一体、行列混合	存算一体、多模存储	存算分离、多模存储、冷热分离 开放存储（Iceberg/Paimon 等）
AI 能力	缺失	缺失	在线 AI	在离线统一 AI

AI 数据库的底座 必须装得下一切数据形态



对象存储 正在成为 AI 数据库的统一底座

计算层

多模计算引擎
存算分离，弹性扩展

数据层

统一多模数据
统一管理与服务

对象存储层

对象存储
统一、弹性、高可靠、低成本



从关系表到多模表

非结构化数据成为数据库的一等数据资产

上层保持统一的数据库表语义

同一事务　同一权限　同一版本　同一生命周期

用户看到的仍是一张表

media_id	biz_id	created_at	region	raw_file LOB	metadata JSON	embedding
10001	BIZ-20240501	2026-06-29 10:30	华东	image / audio / video / doc	{"type":"image", ...}	[0.13, -0.42, ...]

结构化字段

LOB / JSON / 向量作为表字段统一入表，通过AI列保证一致性

LOB 根据大小选择不同存储形态

小对象 InRow 嵌入主表行

一次 IO 读取多行，减少小对象 IO

大对象 OutRow LOB locator + chunk

主表保存定位符，数据放在对象存储

超大文件 OSS 对象存储托管

超大文件、冷数据托管在外部对象存储

AI 负载：从关系查找到混合搜索

同一张表完成关系 / 全文 / 向量 / 图搜索与 AI 计算

01 用户看到一张多模表

融合结构化与无结构化数据

call_id | audio | transcript | json | embedding

统一表视图

- 结构化数据
- LOB 数据
- AI 列回流

多模表实现强一致性

02 混合搜索统一召回

一次查询融合多路能力

- **关系过滤** 圈范围
- **全文搜索** 找相同
- **向量搜索** 找近似
- **图搜索** 找相关

多路召回 + 粗排

03 先过滤，再调用模型

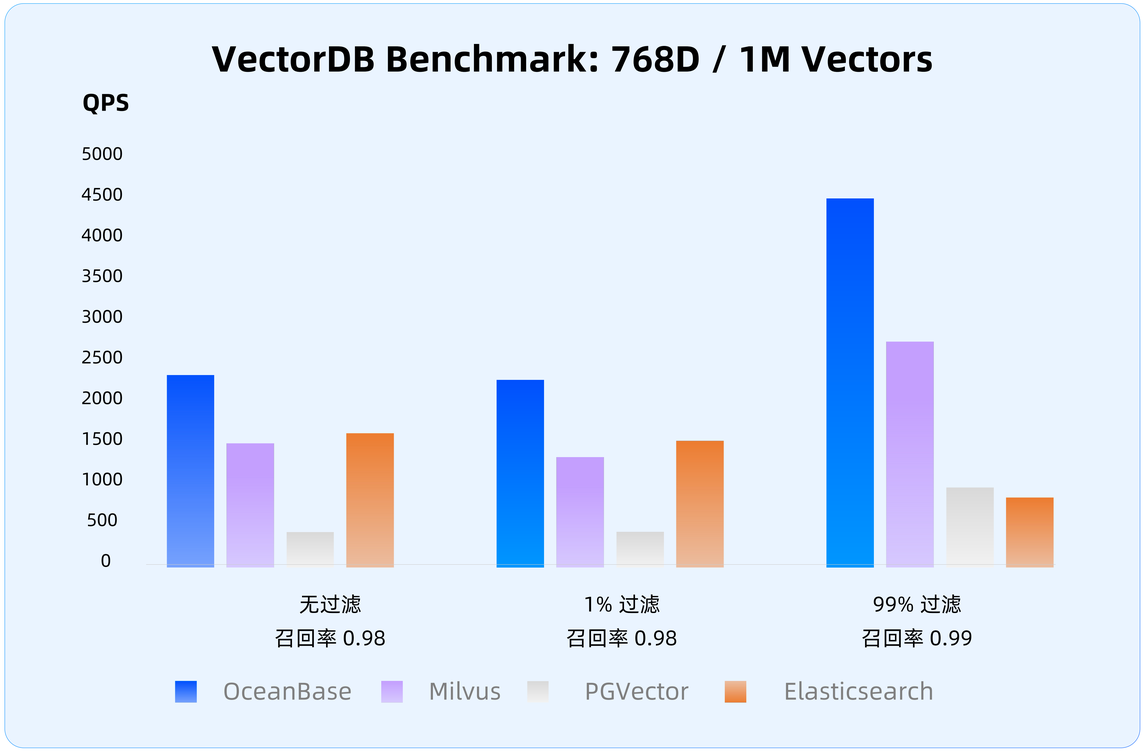
节省 Token，结果更可控

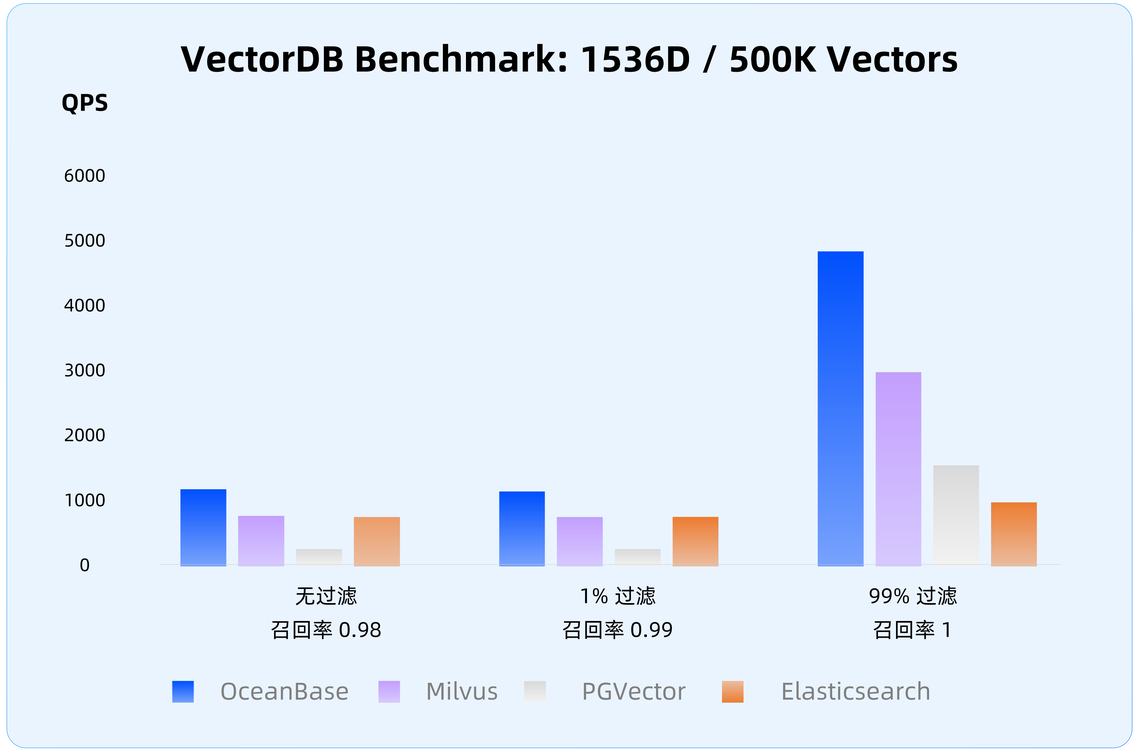
- 全量数据
- 候选集
- 模型精排
- 结果返回

数据库先缩小范围，模型只处理高价值候选

数据入库即智能，搜索即融合，模型调用更省、更准、更可控

AI 负载：极致向量性能





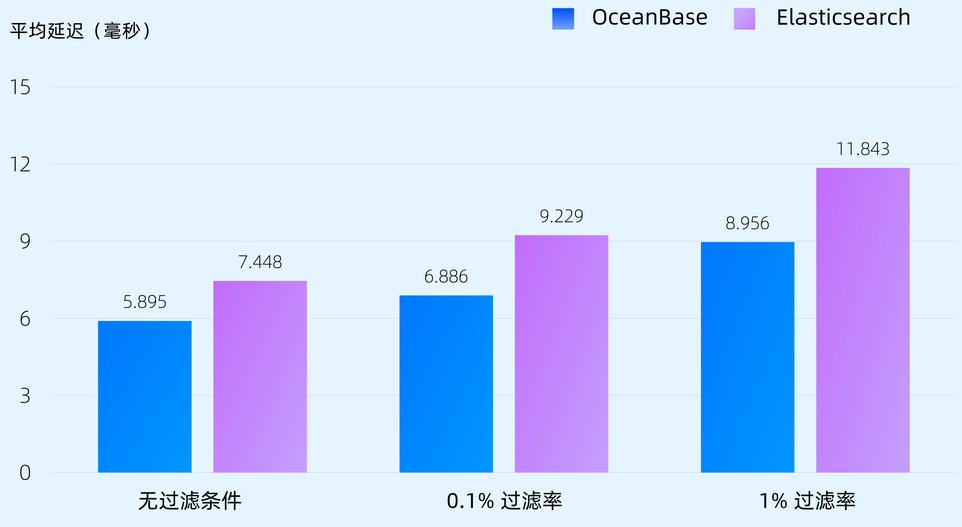
同等召回率下，OceanBase 向量性能领先，为大规模 AI 负载提供高性能底座

测试版本：OceanBase 4.3.5，Milvus 2.5.11，PostgreSQL 17.4 + pgvector 0.8.0，Elasticsearch 9.0.0；AWS m6id.4xlarge（16C64G）

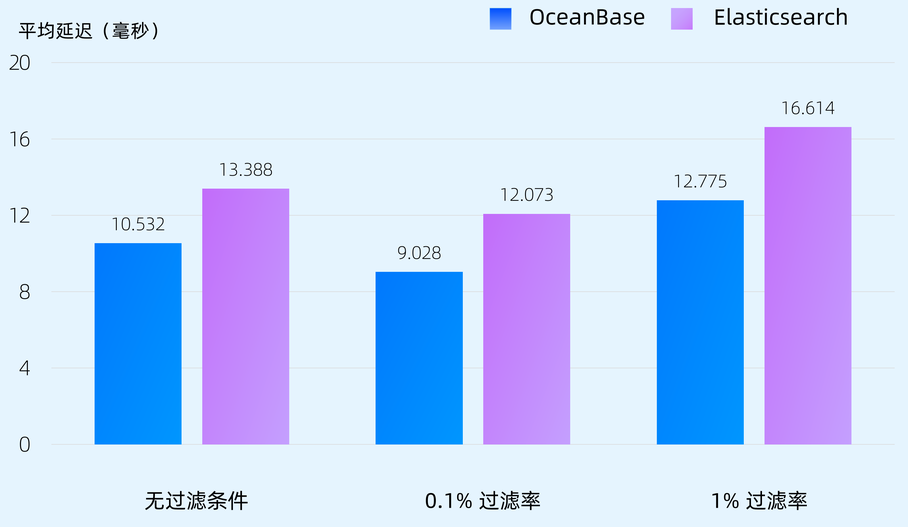
AI 负载：混合搜索正在回到数据库本体

MSMARCO 数据集，880 万 Passage 测试

Top10 平均延迟



Top100 平均延迟



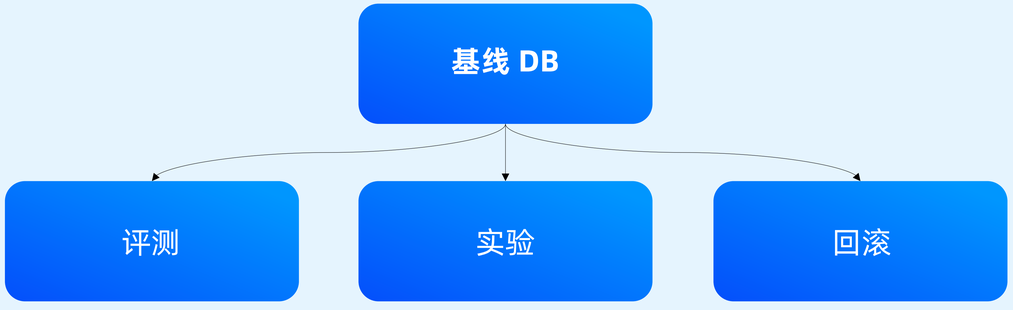
OceanBase 混合搜索性能优于 Elasticsearch 30%+

从人类友好到 Agent 友好

支持海量 Agent 并行运行 可试错 可回滚

Fork Database：快速试错

每个 Agent 可从基线库 Fork 出独立数据沙箱



- 秒级创建
- 读写隔离
- 失败可回滚

逻辑表：面向海量 Agent

每个 Agent 有独立数据边界，共享底层资源池

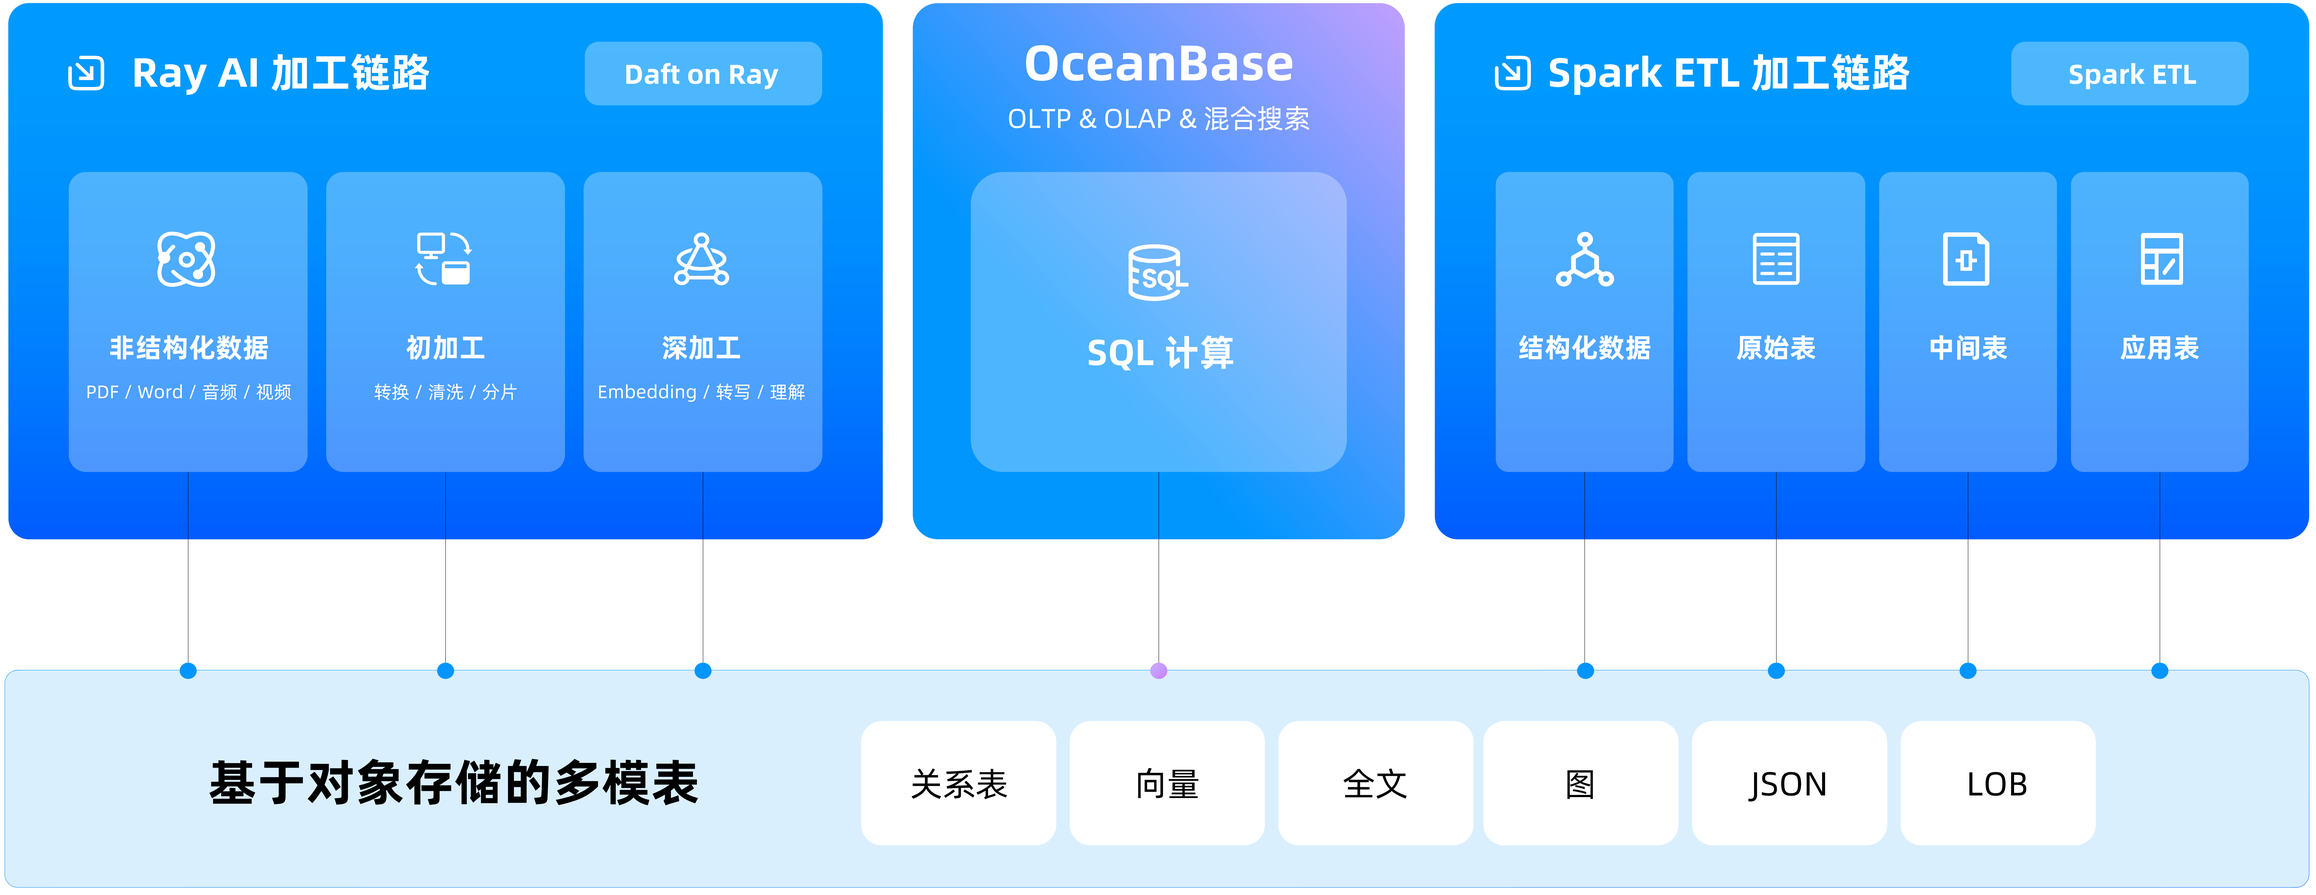


- 逻辑隔离
- 冷热分离
- 按需唤醒
- 闲时资源归零

单个 Agent 安全试错 → 海量 Agent 低成本并行运行

从 SQL 计算到开放计算

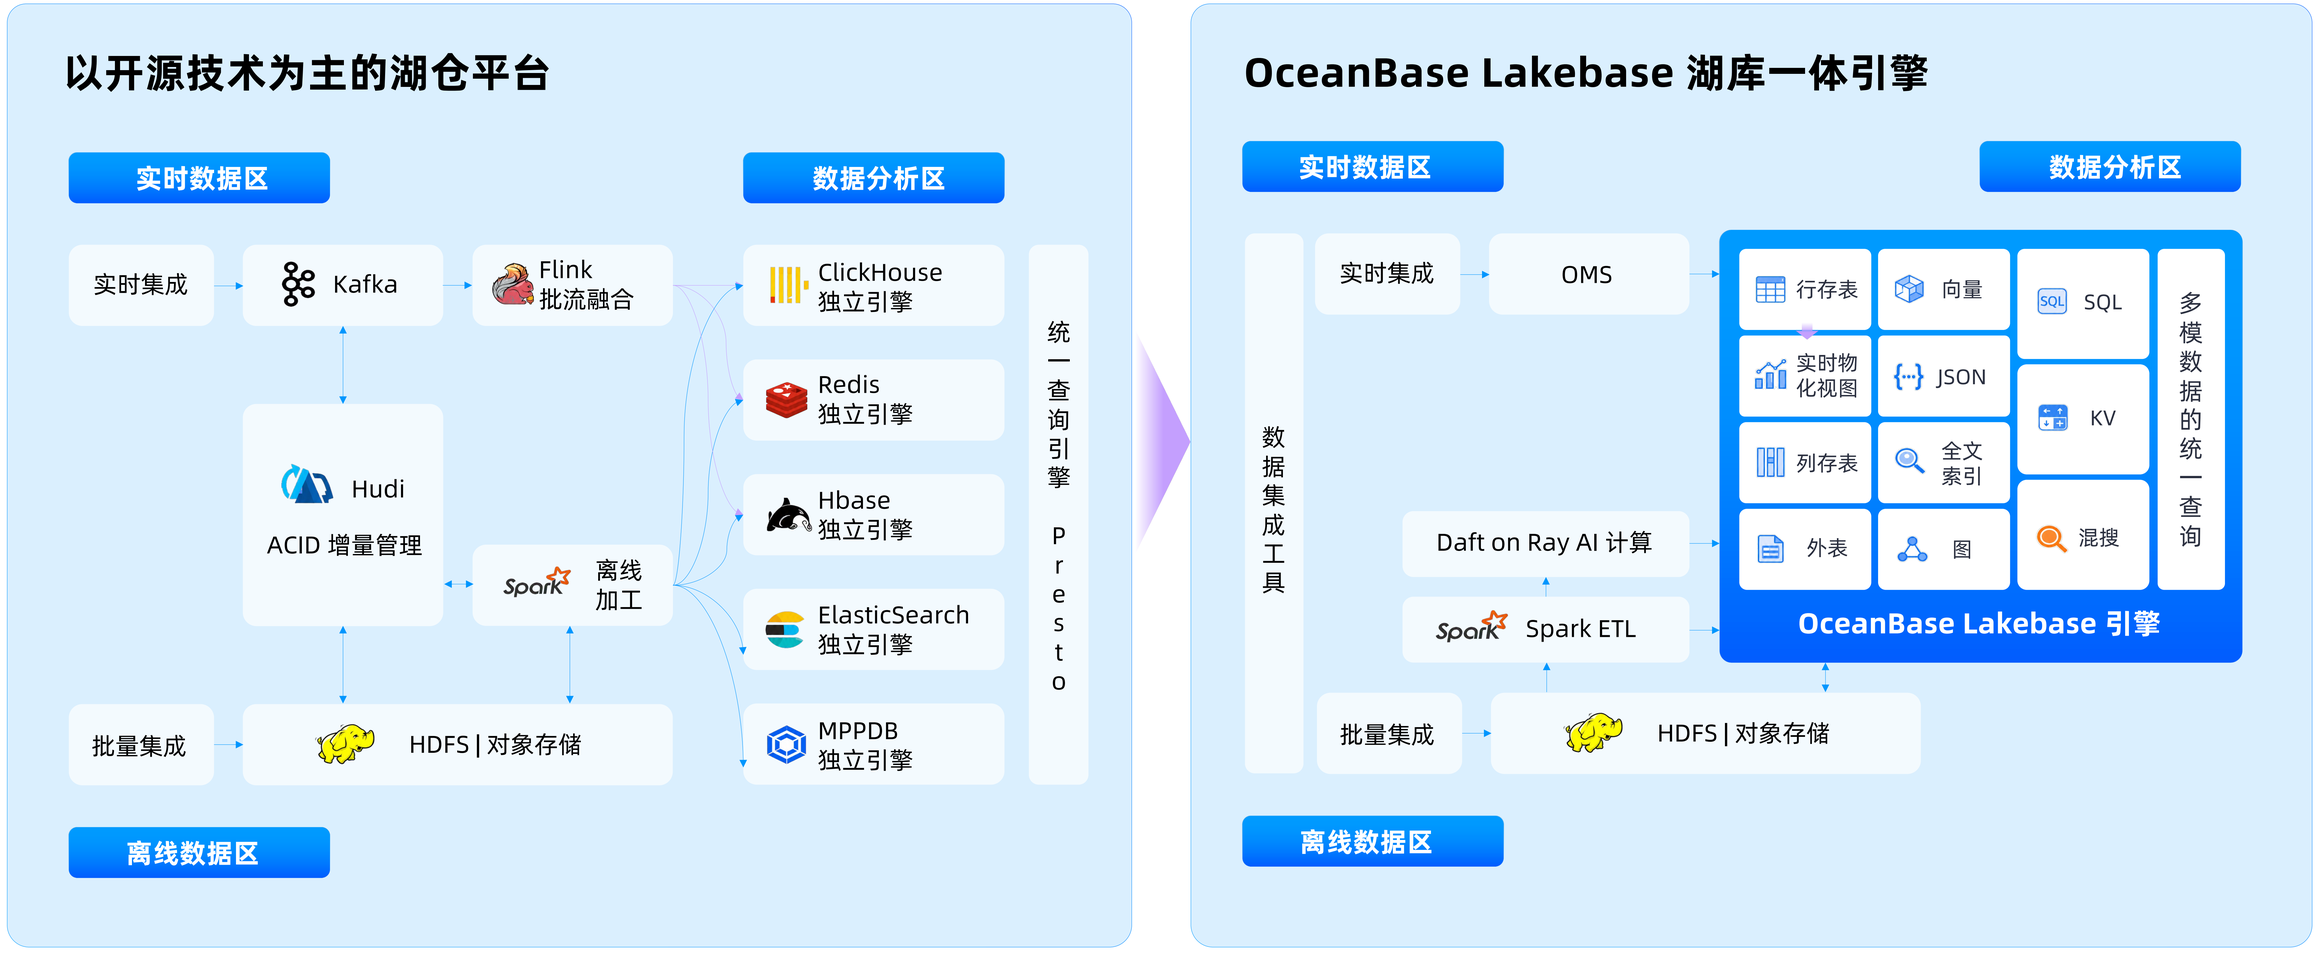
一份数据同时服务所有计算引擎



AI 数据安全不是补丁 是从元数据底座长出来的



一套技术栈 融合处理多模态数据 实现在离线统一



AI 数据库与应用之间 缺的不是接口 是上下文



Agent 记忆不是堆上下文，是可进化的结构化资产

PowerMem 关键特性

核心不是堆上下文，而是把对话沉淀成结构化、分层、可搜索的记忆资产

事实抽取

偏好 / 意图 / 时间信息

冲突合并

ADD / UPDATE / DELETE / NONE

混合搜索

向量 + 全文 + 标量

经验蒸馏

轨迹提炼 / 去重 / skill_refs

技能蒸馏

步骤 / 陷阱 / 修复方法

遗忘与治理

重要性评分 / 多租户隔离

Hermes 评测对比：AppWorld 公平蒸馏实验

同一份 54 条轨迹 · 同一模型 GPT-4o · 唯一变量 = 蒸馏 + 搜索

39%	6.2	32%↓
通过率	**平均完成步数**	**Token 消耗**
21/54；Hermes 22%	Hermes 10.4	基线 2.56M 降至 1.74M

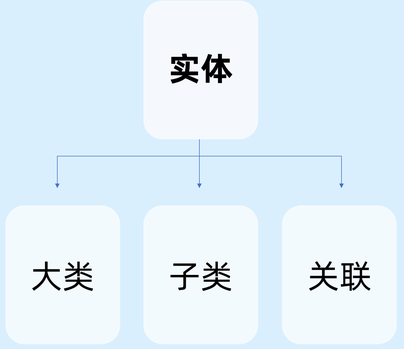
方案	通过率	平均步数	结论
M0 + Experience → Skill	39%	6.2	语义搜索 + 轻量经验
Hermes + SKILL.md	22%	10.4	全量注入 干扰决策

PowerMem + seekdb M0：让 Agent 记忆可进化、可治理、可复用。

高质量的语义上下文是最后一公里

OceanBase OSI =

本体层



基于本体统一全局语义标准
自动处理局部与全局语义冲突

+

上下文图谱



基于知识图谱提供推理能力
自动建模，冷启动准确率高

+

语义层

指标定义

计算逻辑

底层原始数据

基于 Ant-OSI 的开放语义层
统一口径，跨平台互通
Agent 原生，语义即代码

OceanBase 湖库一体的 AI 数据库



OceanBase AI 数据库

让企业 **更准、更省、更快、更安全** 地使用 AI

OceanBase

谢谢